

分类效果评估与边界 case 分析报告

1. 分析目的

第一版中使用 `gpt-oss:20b` 对 CSDS 对话做“快递 / 邮政相关”二分类。反馈要求补充说明：已有二分类结果是否做过探查、整体情况如何、是否存在边界 case、是否有量化指标评估分类效果，并建议用 Regex 分析总结字段中的关键词来打标签。

本报告只围绕两个结果做二分类对照：

- 1. 已完成的 `gpt-oss:20b` 二分类结果。
- 2. 基于总结字段关键词构造的 Regex 弱标签。

2. Regex 规则

Regex 是基于总结字段关键词构造的可解释对照标签，用来量化 20B 结果与关键词规则的一致性，并定位边界样本。

二分类 Regex 使用的关键词包括：


邮政、中国邮政、EMS、ems、邮局、邮政快递、邮政包裹、特快专递、挂号信、平邮、邮政编码、邮政网点、邮政营业厅、商务件、
快递、物流、配送、派送、配送员、快递员、送货员、站点、分站、网点、自提点、提货点、派件点、配送点、
分拣、分拨、分部、揽收、取件、上门取件、上门取货、签收、拒收、收货、收件、寄回、寄出、寄送、
邮寄、包裹、运费险、运费、发货、到货、送达、送到、清关、海关、转站点、拦截、代收、货到付款

业务类 Regex 使用的关键词包括：

类别	关键词
费率价格类	运费、邮费、多少钱、价格、费用、收费、保价、报价、首重、续重
时限时效类	几天、多久、什么时候到、时效、预计、送达、到达、延误、超时、派送、物流、快递
流程规则类	怎么寄、怎么下单、修改地址、地址写错、取消、退回、签收、揽收、取件、上门、站点、网点、流程、规则
禁限寄类	禁寄、限寄、不能寄、可以寄吗、违禁、液体、电池、药品、食品、化妆品、危险品
国际业务类	国际、国外、海外、海关、清关、报关、跨境、进口、出口

3. 各 split 标签规模

split	总样本数	20B 判为相关	Regex 命中
train	9101	5376 (59.07%)	5013 (55.08%)
val	800	459 (57.38%)	440 (55.00%)
test	800	486 (60.75%)	438 (54.75%)




20B 判相关比例约为 59.07%，Regex 命中比例约为 55.05%。二者规模接近，说明 20B 的二分类结果主要覆盖了快递、物流、配送、订单流转等宽口径客服场景，整体方向与可解释关键词规则基本一致。

4. 20B 与 Regex 对照

标签组合	样本数	占比
20b=True regex=True	5102	47.68%
20b=True regex=False	1219	11.39%
20b=False regex=True	789	7.37%
20b=False regex=False	3591	33.56%

20B 二分类与 Regex 对比



20B 与 Regex 同时判为相关的样本有 5102 条，占全量 47.68%。这部分通常包含快递、物流、配送、取件、签收、站点、运费等显式业务词，是当前二分类结果中最容易解释的一类样本。

边界 case 主要来自两类：


- 1. 20b=True regex=False：20B 判为相关，但总结字段没有命中 Regex。可能是模型根据完整对话上下文识别出的隐性物流场景，也可能是 20B 误收。
- 2. 20b=False regex=True：Regex 命中，但 20B 判为不相关。可能是关键词出现在发票、售后、安装、会员等非寄递主题中，也可能是 20B 漏判。

因此，Regex 的价值是提供一个透明的对照视角和边界样本池，而不是替代模型输出。

5. Regex 业务类弱标签分布

类别	命中数	占比
流程规则类	4264	32.54%

类别	命中数	占比
时限时效类	3202	24.44%
费率价格类	1333	10.17%
国际业务类	77	0.59%
禁限寄类	57	0.43%
未命中	4171	31.83%



Regex 业务类弱标签显示，当前数据中流程规则类和时限时效类最多，费率价格类有一定规模，国际业务类和禁限寄类较少。这与客服对话中常见的地址修改、签收拒收、配送时效、运费咨询等问题结构相符。

6. 结论

20B 与 Regex 的整体规模接近，说明第一版 20B 二分类结果并不是无依据扩张，而是大体落在快递、物流、配送和订单流转相关的宽口径场景中。

本报告的结论只基于 20B 与 Regex 对照：20B 给出已有二分类结果，Regex 给出可解释关键词弱标签。二者都服务于“第一版二分类结果是否合理、边界样本在哪里”这个问题。